

文脈と言語慣習が衝突するとき

多言語 LLM における語彙的仲裁の分解

When Context and Language Disagree

今回: scientific question の明確化・先行研究境界・五種類の controls

前回の観察から scientific question へ

前回

誤答は二種類の
failure を
混ぜていないか?

context を利用しない

正しい方向へ動くが最終的に
誤る

今回: So
what?

cross-lingual lexical
error は
どの計算段階で生じる
のか?

semantic-evidence
extraction

lexical decision / arbitration

「FF が難しい」ではなく failure
localization

先行研究：既に問われたことを contribution にしない

Work	既に行ったこと	claim 不可	残る差分
Stingray	FF/cognate • 4 pairs • bias	FF が難しい／多言語化	Language×Sense の分離
Tanwar	3 word types • context • incongruent	矛盾文／3 分類	stage-specific estimand
Doppel	JC 3 tasks • shortcut • POS	JC error analysis	誤答内の context evidence
RoDEval	WSD knowledge/bias/reliability	accuracy 不十分	exact-form conflict 分解
Dumas / Oh	patching • context/lexical competition	表現分離／競争の初研究	cross-lingual collision

Main RQ : 抽出失敗か, 仲裁失敗か

文脈が支持する語義と言語慣習が支持する語義が衝突するとき,
誤りは文脈語義の抽出段階か, 抽出後の最終語義選択か?


R
Q1
Evidence
extraction
Language 固定
・ Sense のみ変更

R
Q2
Collision
specificity
五種類の
matched
controls

R
Q3
Arbitration
mechanism
target residual /
MLP

**B = behavioral backbone → A = conditional
mechanistic explanation**

仮説: 正しい evidence があっても答えは誤り得る



pilot が示唆する
paradox
context evidence
は正方向
しかし decision
boundary を越えない

研究価値

failure diagnosis が変わる
一般 WSD と collision を分ける
remedy の対象段階が変わる

RQ1 : Language × Sense の完全 2×2

	Sense 1 context	Sense 2 context	Semantic effect
Language 1	L1 × S1	L1 × S2	同じ言語のまま S1 → S2

Language 2 L2 × S1 L2 × S2

Language effect

同じ sense の
まま
L1 → L2

exact same form

target mask

language-only

marker-matched unrelated

repeated gloss / natural data

現在の behavioral evidence : 誤答内部に context signal

Condition	CI > 0
Full context	92 / 96
Target masked	91 / 96
Language only	4 positive / 2 negative
Matched unrelated	1 positive / 3 negative

Generality gates

official chat: full 48/48

natural

masked-unrelated:
82/96

ID-MS / ID-TL: 48/48

Doppel natural: 4/4
models

Correct semantic evidence can be present without yielding the correct lexical decision.

RQ2：五種類の controls（novelty ではなく identification）

Type	Form	Semantics	役割
False friend	same exact	different	target conflict
True friend	same exact	same	shared-form baseline
Language-specific	one language only	—	ordinary lexical processing
Different-form translation	different	same	no form collision
Monolingual polysemy	same / one language	different senses	ordinary WSD

先生の minimum baseline：最初の三種類

追加二種類：form sharing と ambiguity を分離

Outcome-blind matching : 旧 control の失敗を設計で修正

旧 pool :

FAIL

exact bilingual POS
+ every covariate ≤ 1 SD

0 pairs

→ causal claim に使わ
ない

**新 target-first
design**

11,000 natural-context
candidates

24 / 27 false friends retained

24 true + 24 translation

max |SMD| = .087 / .097

4× validation reservoir:

96/group

Qwen3/Gemma outcomes 未読

POS • frequency • ratio • length •
tokenization • Qwen2.5 difficulty

追加した language-specific control

操作的定義

NFKC exact form が相手言語辞書に存在しない二字語

自然文 pool : ZH 7,943 / JA 7,923

final : ZH 23 / JA 24 , $\max |SMD| = .094 / .097$


4× reservoir : ZH 92 / JA 96 , $\max |SMD| < .10$

frequency / length / Qwen3 • Gemma token / gloss / Qwen2.5
difficulty

辞書非掲載 $\neq$ 絶対不存在 $\rightarrow$ human validation 必須

**役割: cross-language LCE ではなく, 通常の one-language context
extraction / decision baseline**

RQ3 : B が paradox を発見し, A が条件付きで説明する



現在の解釈

semantic profile は
ordinary WSD-like

target residual で両
signal が causal

MLP は主要 language
signal を再現

attention-only は不安
定

claim しない

homograph circuit /
neuron

人間脳との同一性

次週までの hard gates と判定規則

- 1 Doppel 708 rows $\times$ 2 bilinguals
- 2 true/translation 192 $\times$ 2
- 3 language-specific 188 $\times$ 2
- 4 human-valid set で再 matching
- 5 ≥ 20 FF, all $|SMD| \leq .10$ のみ unlock

失敗時: collision-specific mechanism を削除。
B の behavioral decomposition は独立に評価。

今回、先生に確認したい点

Main RQ を「context extraction vs lexical arbitration の failure localization」としてよいか

B を主 contribution , matched causal A を条件付き第二 contribution としてよいか

language-specific を one-language extraction/decision baseline とする設計でよいか

中日 bilingual annotator 二名をどのように確保するか

示したいこと：モデルは文脈を理解していても、語彙的仲裁で負けて誤答し得る。